Dalla musica all'arte visiva

Riconoscimento delle emozioni, Stable Diffusion e valutazione CLIP

Silvia Mucci
Dipartimento di Ingegneria Civile, Informatica e delle Tecnologie Aeronautiche
Università degli Studi Roma Tre
Corso: Artificial Intelligence From Engineering to Arts
Matricola: 546922

Abstract

Questo lavoro presenta un sistema di Intelligenza Artificiale che integra il riconoscimento delle emozioni musicali con la generazione automatica di immagini astratte e figurative. A partire da un brano audio, vengono estratte caratteristiche musicali utilizzate per classificare l'emozione prevalente in una delle quattro categorie considerate. Il risultato della classificazione, insieme ad alcune proprietà del segnale, viene tradotto in un prompt testuale che guida la generazione delle immagini attraverso Stable Diffusion v1.5.

La fase sperimentale prevede il confronto tra diversi algoritmi di machine learning e differenti durate di analisi audio, individuando in Extra Trees la configurazione più efficace secondo il criterio di selezione adottato. Il progetto approfondisce inoltre il ruolo del prompt nella generazione di rappresentazioni astratte e figurative dello stesso contenuto musicale. Infine, attraverso il modello CLIP, viene effettuata una valutazione esplorativa della coerenza semantica tra le immagini generate e le emozioni associate ai brani.

1 Introduzione

La musica può evocare emozioni attraverso ritmo, intensità, timbro e armonia. Il riconoscimento automatico di queste emozioni, noto come *Music Emotion Recognition* (MER), combina l'elaborazione dei segnali audio con metodi di machine learning. Il presente progetto esplora un'applicazione creativa di tale processo: trasformare l'informazione emozionale contenuta in un brano in un contenuto visivo generato automaticamente.

Il lavoro si articola in tre contributi:

- il confronto sperimentale tra algoritmi e durate di analisi per la classificazione emozionale;
- la realizzazione di una pipeline dalla musica all'immagine, con due modalità di generazione;
- una valutazione esplorativa della coerenza semantica delle immagini mediante CLIP.

Le sezioni successive approfondiscono i fondamenti teorici del progetto, il funzionamento del sistema sviluppato, la metodologia sperimentale adottata e l'analisi dei risultati ottenuti, considerando sia le prestazioni dei modelli di classificazione sia gli aspetti qualitativi delle immagini generate.

2 Stato dell'arte

2.1 Riconoscimento computazionale delle emozioni musicali

Il *Music Emotion Recognition* mira ad associare a un segnale musicale un'etichetta o una rappresentazione emozionale. Negli approcci tradizionali il brano viene convertito in un vettore di caratteristiche che descrivono aspetti ritmici, energetici, spettrali, timbrici e armonici, successivamente elaborato da un classificatore supervisionato. Tra i descrittori impiegati figurano tempo, energia RMS, zero-crossing rate, spectral centroid, spectral rolloff, spectral contrast, chroma e MFCC [3, 4]. La loro combinazione consente di descrivere proprietà complementari del segnale, senza assumere che una singola caratteristica determini un'emozione.

Un'alternativa è rappresentata da modelli di deep learning che apprendono rappresentazioni da forme d'onda o spettrogrammi. In questo progetto si utilizza invece un approccio basato su feature esplicite e classificatori tradizionali, così da confrontare modelli su un dataset relativamente contenuto e analizzare il contributo dei descrittori. Questa scelta riguarda la metodologia sperimentale adottata e non implica una superiorità generale rispetto alle architetture neurali.

2.2 Generazione visiva condizionata

Nel dominio delle immagini, i modelli generativi comprendono, tra gli altri, le *Generative Adversarial Networks* (GAN) e i modelli di diffusione. Le GAN addestrano una rete generatrice e una discriminatrice in competizione [6], mentre i modelli di diffusione apprendono a invertire progressivamente un processo di aggiunta di rumore [7]. Nei *latent diffusion models*, la generazione avviene in uno spazio di rappresentazione compresso, riducendo il costo computazionale rispetto al lavoro diretto sui pixel [8].

Stable Diffusion appartiene a quest'ultima famiglia e può essere condizionato da un prompt testuale. La possibilità di specificare atmosfera, palette, forme e contenuto della scena rende tale approccio adatto alla traduzione visiva di descrizioni ricavate dalla musica.

3 Sistema proposto

Il sistema collega l'analisi di un file audio alla generazione di un'immagine mediante sei passaggi:

- acquisizione e preparazione del segnale;
- estrazione delle feature;
- classificazione emozionale;
- costruzione del prompt;
- generazione con Stable Diffusion;
- valutazione esplorativa con CLIP.

L'emozione predetta guida l'impostazione generale della composizione, mentre alcuni descrittori musicali contribuiscono a differenziare i prompt all'interno della stessa classe. La modalità visiva può essere astratta oppure figurativa.

3.1 Dataset e organizzazione delle classi

L'addestramento e la valutazione dei classificatori si basano sul *4Q Audio Emotion Dataset*. Le etichette del dataset seguono una rappresentazione bidimensionale delle emozioni ispirata al modello *valence–arousal* di Russell [2]. La **valence** descrive la connotazione positiva o negativa dell'emozione, mentre l'**arousal** ne indica il grado di attivazione. Dalla combinazione delle due dimensioni derivano quattro quadranti, associati in questo lavoro alle classi riportate nella Tabella 1. Il modello permette di organizzare in modo semplice le etichette disponibili.

Quadrante	Valence	Arousal	Classe
Q1	positiva	alta	happy
Q2	negativa	alta	tense
Q3	negativa	bassa	sad
Q4	positiva	bassa	calm

Tabella 1: Corrispondenza tra quadranti valence–arousal e classi del dataset.

Dopo il caricamento e il controllo dei file, il dataset comprende 900 clip, equamente distribuite tra *happy*, *calm*, *tense* e *sad*, con 225 esempi per classe. Tale bilanciamento evita che una categoria prevalga numericamente sulle altre, pur non eliminando le possibili difficoltà nel distinguere emozioni acusticamente simili. La distribuzione è illustrata nella Figura 1.

3.2 Preparazione del segnale audio

Per uniformare i dati, ogni file viene caricato a una frequenza di campionamento di $f_s = 22\,050\,\text{Hz}$ e convertito in mono. La frequenza di campionamento indica il numero di campioni acquisiti ogni secondo; la conversione mono evita differenze dovute al numero di canali. Dopo il caricamento della porzione iniziale del brano viene applicato il *trimming*, che rimuove gli intervalli silenziosi alle estremità del segmento e limita la loro influenza sulle caratteristiche calcolate.

Per verificare come varia la classificazione al cambiare della quantità di audio disponibile, vengono analizzate quattro durate massime: 10, 20, 30 e 60 secondi. Poiché le clip del dataset durano approssimativamente 30 secondi, l'ultima configurazione utilizza in pratica il segnale completo, senza garantire 60 secondi effettivi. Il confronto riguarda quindi i limiti di caricamento impostati e non dimostra l'effetto di raddoppiare la durata reale del brano.

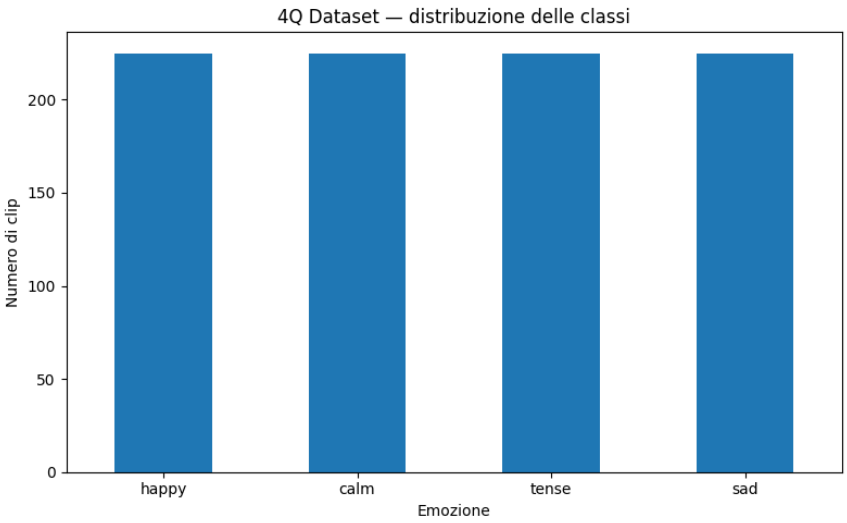


Figura 1: Distribuzione delle 900 clip audio nelle quattro classi emozionali. Ogni classe contiene 225 esempi.

3.3 Rappresentazione numerica del brano

Ogni clip preprocessata è rappresentata da un vettore di 130 feature, che riassume informazioni ritmiche, energetiche, spettrali, timbriche e armoniche.

Ritmo, energia e variazioni del segnale

Il *tempo*, espresso in battiti per minuto (BPM), stima la velocità ritmica del brano, mentre l'*onset strength* misura l'intensità degli attacchi musicali e delle variazioni improvvise. L'energia *Root Mean Square* (RMS) descrive l'ampiezza media quadratica del segnale: per una finestra di N campioni si definisce come

$$\mathrm{RMS} = \sqrt{\frac{1}{N}\sum_{n=1}^{N} x_n^2},$$

dove x_n è il campione audio in posizione n. Valori elevati indicano una maggiore intensità del segnale, che può contribuire, insieme agli altri descrittori, a distinguere brani con livelli differenti di attivazione.

Lo *zero-crossing rate* (ZCR) quantifica invece la frequenza con cui il segnale attraversa lo zero. Una sua possibile formulazione normalizzata è

$$\mathrm{ZCR} = \frac{1}{2N}\sum_{n=1}^{N} \left|\mathrm{sgn}(x_n) - \mathrm{sgn}(x_{n-1})\right|.$$

Questa misura può essere elevata nei segnali con componenti rumorose o percussive, ma non consente da sola di identificare un'emozione.

Distribuzione spettrale

Le caratteristiche spettrali descrivono la distribuzione delle componenti in frequenza. Lo *spectral centroid*, spesso associato alla brillantezza percepita, rappresenta il centro di massa dello spettro:

$$C_t = \frac{\sum_k f_k S_t(k)}{\sum_k S_t(k)},$$

dove $S_t(k)$ è l'ampiezza della componente k al tempo t e f_k la frequenza corrispondente. Il *spectral rolloff* individua una frequenza-soglia al di sotto della quale ricade una quota prefissata dell'energia spettrale; lo *spectral bandwidth* misura la dispersione attorno al centroide. Infine, lo *spectral contrast* descrive la differenza tra picchi e valli dello spettro in più bande di frequenza, offrendo informazioni sulla struttura timbrica del segnale.

Armonia e timbro

I coefficienti *chroma* riassumono l'energia distribuita tra le dodici classi di altezza della musica occidentale, indipendentemente dall'ottava, e forniscono informazioni sulle componenti armoniche prevalenti. Da questi valori viene ricavata anche una stima semplificata della modalità maggiore o minore. Gli *Mel-Frequency Cepstral Coefficients* (MFCC) sintetizzano invece aspetti timbrici del segnale mediante una rappresentazione collegata alla percezione uditiva. Oltre agli MFCC vengono calcolati i coefficienti *delta* e *delta-delta*, che descrivono rispettivamente variazioni temporali di primo e secondo ordine e permettono di rappresentare l'evoluzione del timbro nel segmento.

Aggregazione temporale e valori mancanti

Per le caratteristiche calcolate nel tempo, il vettore finale comprende statistiche riassuntive, in particolare media e deviazione standard. Indicando con z_t il valore di una feature nella finestra t, esse sono definite da

$$\mu_z = \frac{1}{T}\sum_{t=1}^{T} z_t, \qquad \sigma_z = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(z_t - \mu_z)^2}.$$

La prima descrive il livello medio della caratteristica, la seconda la sua variabilità. Eventuali valori mancanti, infiniti o non validi vengono sostituiti con la mediana stimata esclusivamente sui dati di training, così da non utilizzare informazioni del test set nella preparazione del modello.

3.4 Classificazione dell'emozione

Il vettore delle 130 feature alimenta un classificatore supervisionato che assegna il brano a una delle quattro classi $\mathcal{C} = \{happy, calm, tense, sad\}$. Sono confrontati quattro modelli:

- **Random Forest**, che combina le predizioni di numerosi alberi decisionali;
- **Extra Trees**, che introduce una maggiore casualità nella costruzione degli alberi;
- **Support Vector Machine** (SVM) con kernel RBF, capace di definire separazioni non lineari;
- **Regressione Logistica**, usata come riferimento lineare [5].

3.5 Dal profilo musicale al prompt visivo

La descrizione testuale destinata a Stable Diffusion combina cinque informazioni: emozione predetta, tempo, energia RMS, centroide spettrale e modalità maggiore o minore. L'emozione definisce l'orientamento estetico generale, mentre gli altri descrittori modificano il ritmo visivo, l'intensità cromatica, la luminosità e il carattere della composizione. Le associazioni di base, definite nel progetto, sono le seguenti:

- *happy*: colori luminosi e forme arrotondate, con un movimento dinamico;
- *calm*: tonalità tenui, forme fluide e composizioni minimali;
- *tense*: contrasti marcati, colori scuri e linee irregolari;

- *sad*: blu, viola e grigi, forme sfumate e atmosfere malinconiche.

La costruzione del prompt può essere sintetizzata come $P = g(\hat{y}, b, e, c, m)$, dove $\hat{y}$ è la classe emozionale predetta, b il tempo, e l'energia RMS, c il centroide spettrale e m la modalità stimata. La funzione g è una procedura progettata nel codice, non un ulteriore modello addestrato. I valori continui vengono tradotti in descrittori categoriali confrontandoli con riferimenti stimati sul training set: perciò brani con la stessa etichetta possono ricevere prompt differenti se presentano profili musicali diversi.

Nella **modalità astratta**, il prompt richiede una composizione non figurativa; il *negative prompt* scoraggia testo, firme, volti, oggetti riconoscibili, paesaggi e altri elementi realistici. Nella **modalità figurativa**, invece, il prompt richiede una scena riconoscibile senza imporre uno specifico soggetto o luogo, e il negative prompt mira soprattutto a evitare testo, loghi, duplicazioni e deformazioni. In entrambe le modalità rimangono gli stessi descrittori audio: cambia soltanto la loro traduzione in istruzioni visive, non il classificatore né l'addestramento del modello generativo. Il negative prompt orienta la generazione, ma non garantisce l'assenza completa di artefatti. La costruzione del prompt è riportata nell'Appendice A, così da rendere verificabile il passaggio dalle caratteristiche audio alle istruzioni del modello generativo.

3.6 Produzione dell'immagine con Stable Diffusion

Le immagini vengono prodotte con Stable Diffusion v1.5, utilizzato attraverso la libreria Python `diffusers`. Il modello, già preaddestrato, riceve il prompt positivo e quello negativo; a partire da rumore iniziale determinato da un seed, applica iterativamente un processo di *denoising* nello spazio latente fino a ottenere l'immagine. Non viene effettuato un fine-tuning specifico per i brani musicali o per l'arte astratta.

La configurazione comprende una risoluzione di 512×512 pixel, 30 passi di inferenza, *guidance scale* pari a 7,5 e un seed controllato, con esecuzione su GPU. I passi indicano il numero di iterazioni generative, mentre la guidance scale regola la forza con cui il modello segue il prompt. Il seed permette di controllare il rumore iniziale: mantenendo invariati anche prompt, negative prompt e parametri, la generazione è riproducibile a parità di ambiente e impostazioni computazionali. L'output è quindi un contenuto visivo nuovo, non una visualizzazione diretta della forma d'onda o dello spettrogramma.

3.7 Valutazione semantica delle immagini con CLIP

Per integrare l'analisi qualitativa delle immagini viene impiegato CLIP (*Contrastive Language–Image Pre-training*), un modello preaddestrato che rappresenta testi e immagini in uno spazio semantico condiviso [1]. L'esperimento utilizza la variante `openai/clip-vit-base-patch32`, con quattro descrizioni testuali per ciascuna modalità visiva. Non legge direttamente l'audio e non verifica quindi se l'emozione predetta dal classificatore corrisponda a quella percepita da un ascoltatore.

La similarità tra un'immagine I e il testo T_k è espressa mediante il coseno tra gli embedding:

$$s_k(I) = \frac{f_{\text{img}}(I)^\top f_{\text{text}}(T_k)}{\|f_{\text{img}}(I)\| \, \|f_{\text{text}}(T_k)\|}.$$

La classe attribuita da CLIP è quella con similarità maggiore, $\hat{y}_{\text{CLIP}} = \arg\max_k s_k(I)$. Si osservano sia il punteggio relativo alla classe predetta dall'audio sia la concordanza fra le due etichette. Questi valori non sono probabilità né misure dirette di correttezza emotiva: dipendono anche dalle descrizioni usate.

4 Impostazione sperimentale

4.1 Suddivisione dei dati e selezione dei modelli

Il dataset viene suddiviso mediante uno split stratificato in **80% di training** (720 clip) e **20% di test** (180 clip, 45 per emozione). Sul solo training set viene applicata una *stratified 5-fold cross-validation*: a ogni iterazione quattro fold sono usati per l'addestramento e uno per la validazione. Per ogni durata viene scelto il classificatore con il Macro F1 medio più elevato e la stessa metrica guida il confronto complessivo tra durate. Il test set rimane separato e viene utilizzato soltanto per la valutazione delle configurazioni considerate, non per determinarne la selezione.

4.2 Metriche di classificazione

Le prestazioni dei classificatori sono descritte mediante accuracy, balanced accuracy, precision, recall e F1-score. L'*accuracy* misura la quota complessiva di classificazioni corrette; la *balanced accuracy* è la media del recall sulle classi. La *precision* indica quanto sono affidabili le predizioni assegnate a una classe, mentre il *recall* misura la quota degli esempi reali di quella classe riconosciuti correttamente. L'F1-score sintetizza precision e recall e viene mediato sulle quattro emozioni con uguale peso per ottenere la metrica principale:

$$\text{MacroF1} = \frac{1}{K}\sum_{k=1}^{K} F1_k, \qquad K = 4.$$

L'uso della media macro rende esplicito il comportamento sulle diverse emozioni e non privilegia la classe numericamente più frequente.

4.3 Protocollo del confronto tra modalità visive

L'esperimento di generazione confronta immagini astratte e figurative a partire dagli stessi quattro brani esterni. All'interno di ciascuna coppia rimangono invariati il classificatore Extra Trees a 30 secondi, le feature audio, l'emozione predetta, Stable Diffusion v1.5, la risoluzione di 512×512 pixel, i 30 passi, la guidance scale di 7,5 e il seed. I seed dei quattro brani sono, nell'ordine, 42, 43, 44 e 45. Cambiano lo schema del prompt positivo e il negative prompt, così da mostrare come uno stesso profilo musicale possa essere espresso in due linguaggi visivi. Le rispettive formulazioni sono documentate nell'Appendice A.

Il confronto ha carattere illustrativo e non stabilisce quale modalità riproduca meglio l'emozione.

5 Risultati sperimentali

5.1 Confronto delle durate e dei classificatori

La prima parte dell'analisi confronta quattro durate massime del segmento audio e quattro algoritmi di classificazione. La Tabella 2 presenta, per ciascuna durata, il classificatore selezionato in base al Macro F1 medio nella cross-validation a cinque fold. Per la configurazione a 30 secondi, individuata come migliore secondo questo criterio, sono riportati anche gli altri tre algoritmi, così da rendere esplicito il confronto effettuato.

Durata	Classificatore	CV Macro F1 medio	Test accuracy	Test Macro F1
10 s	SVM RBF	0.6264 ± 0.0518	0.6111	0.6119
20 s	Random Forest	0.6497 ± 0.0292	0.6111	0.6092
30 s	**Extra Trees**	$\mathbf{0.6738 \pm 0.0304}$	**0.6833**	**0.6779**
30 s	Random Forest	0.6619 ± 0.0305	0.6667	0.6609
30 s	SVM RBF	0.6545 ± 0.0291	0.5611	0.5525
30 s	Regressione logistica	0.6166 ± 0.0577	0.5611	0.5548
max 60 s	Random Forest	0.6691 ± 0.0302	0.6556	0.6560

Tabella 2: Confronto tra durate e classificatori. A 10, 20 e massimo 60 secondi è mostrato il modello selezionato; a 30 secondi sono riportati tutti e quattro gli algoritmi.

Extra Trees a 30 secondi ottiene sia il Macro F1 medio più elevato in cross-validation sia i migliori risultati sul test set tra le configurazioni considerate. Random Forest presenta valori relativamente vicini, mentre SVM RBF e regressione logistica risultano meno efficaci nel confronto a 30 secondi. Questa evidenza motiva la scelta di Extra Trees per la pipeline finale, senza dimostrarne una superiorità generale rispetto agli altri modelli.

La Figura 2 mette a confronto accuracy e Macro F1 sul test set nelle quattro durate. Le prestazioni non aumentano in modo regolare all'aumentare della finestra di analisi.

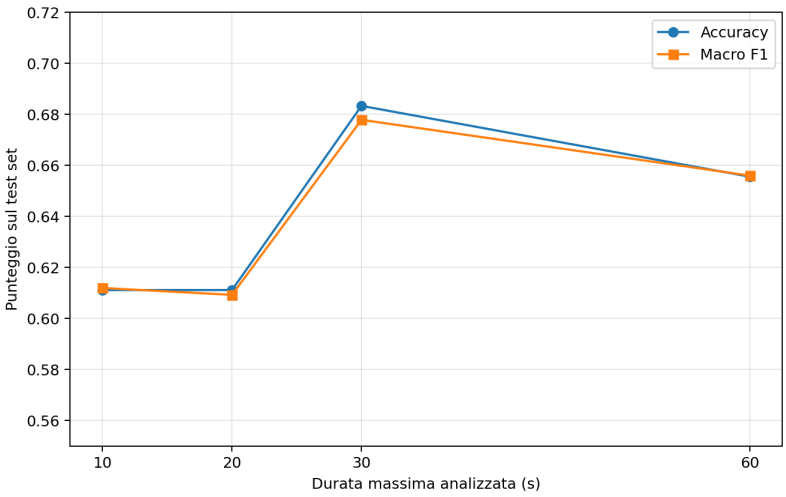


Figura 2: Accuracy e Macro F1 sul test set in funzione della durata massima di analisi.

5.2 Prestazioni nelle singole emozioni

Per approfondire il comportamento del modello selezionato, la Tabella 3 mostra le metriche di Extra Trees a 30 secondi per ciascuna delle quattro classi emozionali. La classe *tense* è riconosciuta

con maggiore efficacia (F1-score pari a 0,86), mentre *sad* presenta il risultato più basso (0,54); *happy* e *calm* si collocano in posizione intermedia. Le metriche complessive non riflettono quindi prestazioni uniformi sulle diverse emozioni.

Classe	Precision	Recall	F1-score	Campioni
happy	0.65	0.76	0.70	45
calm	0.63	0.60	0.61	45
tense	0.83	0.89	0.86	45
sad	0.59	0.49	0.54	45

Tabella 3: Precision, recall e F1-score di Extra Trees a 30 secondi per classe emozionale.

La matrice di confusione nella Figura 3 permette di osservare come si distribuiscono gli errori. Dei 45 brani *tense*, 40 sono classificati correttamente; per *sad*, invece, i riconoscimenti corretti sono 22 e gli errori riguardano soprattutto *calm* (12 casi) e *happy* (9 casi). Questa sovrapposizione suggerisce una maggiore difficoltà nel distinguere alcuni profili emotivi con i descrittori impiegati, ma non permette di identificare con certezza quali caratteristiche acustiche causino tali errori.

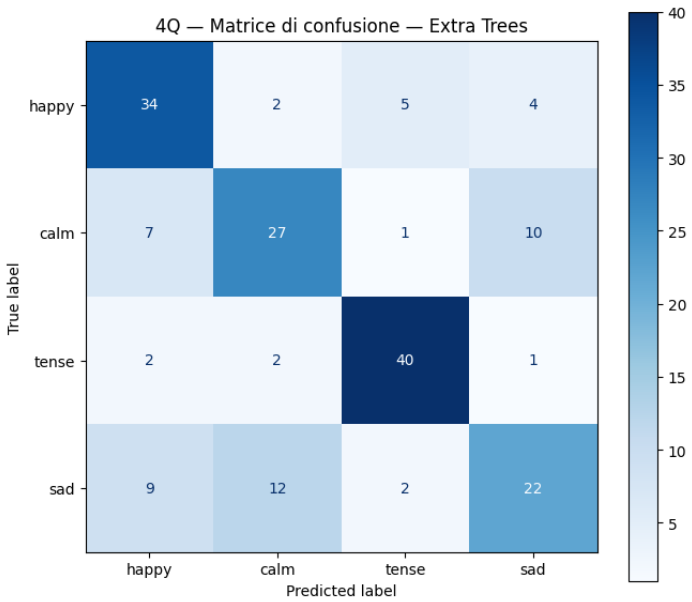


Figura 3: Matrice di confusione di Extra Trees a 30 secondi sul test set.

5.3 Generazione delle immagini e confronto visivo

La configurazione selezionata è stata utilizzata per elaborare quattro brani esterni al dataset di addestramento. Per ciascun brano, l'emozione predetta e alcune caratteristiche musicali sono state convertite in un prompt destinato a Stable Diffusion v1.5. La prima riga della Figura 4 mostra le immagini astratte generate; la seconda presenta le corrispondenti versioni figurative. Il confronto è stato condotto mantenendo invariati, all'interno di ciascuna coppia, il brano, la predizione audio, il seed e i parametri di diffusione. Cambiano soltanto il prompt positivo e il negative prompt, documentati nell'Appendice A. Per *tense*, la composizione astratta impiega contrasti marcati e forme spezzate, mentre quella figurativa propone una scena urbana dinamica; per i due brani *calm*, texture e campi cromatici lasciano spazio ad ambientazioni riconoscibili.

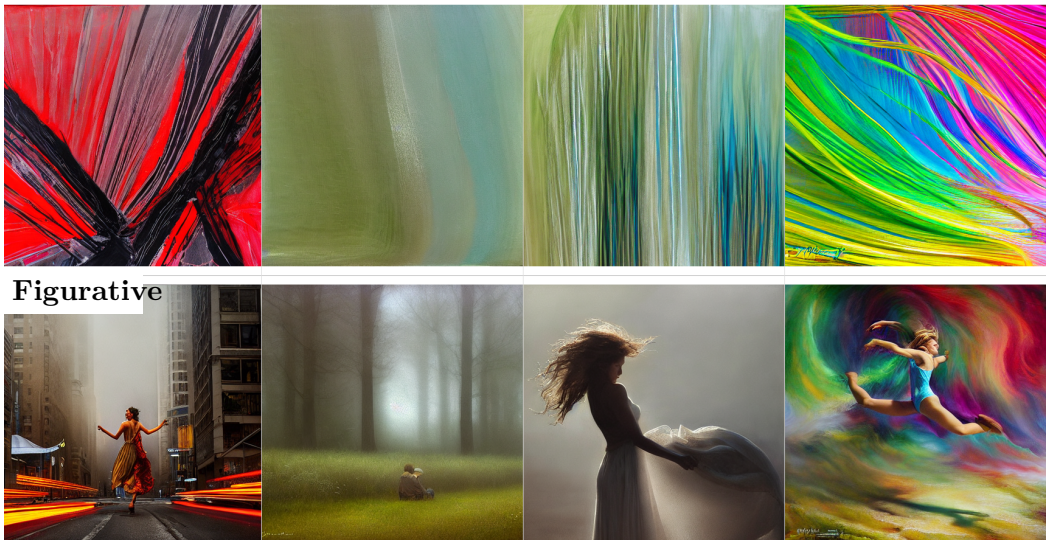


Figura 4: Confronto qualitativo tra immagini astratte (sopra) e figurative (sotto) ottenute dagli stessi quattro brani.

Questi esempi mostrano che uno stesso profilo musicale può essere tradotto in linguaggi visivi diversi modificando le istruzioni testuali. Il confronto non permette tuttavia di stabilire quale modalità trasmetta più fedelmente l'emozione percepita: per verificarlo sarebbero necessari giudizi indipendenti di osservatori umani. Inoltre, la variabilità tra brani distinti non può essere attribuita soltanto alle caratteristiche audio, perché i seed delle diverse colonne non coincidono.

5.4 Valutazione semantica delle immagini con CLIP

La valutazione con CLIP aggiunge un confronto quantitativo esplorativo all'osservazione delle immagini. Per ciascuna modalità, il modello associa all'immagine la descrizione emozionale con similarità maggiore. La Tabella 4 distingue questa *classe CLIP* dal valore numerico riportato, che indica invece la similarità con la classe predetta dal classificatore audio: i due risultati non coincidono necessariamente.

Brano	Emozione audio	CLIP astratto	Sim. astratto	CLIP figurativo	Sim. figurativo
Carnaval	tense	tense	0.278	happy	0.227
Powerful Dramatic Trailer	calm	calm	0.285	calm	0.281
Moment of Peace	calm	calm	0.292	calm	0.289
No Copyright Music	happy	happy	0.280	happy	0.294

Tabella 4: Confronto CLIP sui quattro brani esterni. Le similarità numeriche sono calcolate rispetto all'emozione predetta dal modello audio, non necessariamente alla classe preferita da CLIP.

La classe indicata da CLIP coincide con quella predetta dall'audio in tutte le quattro immagini astratte e in tre immagini figurative su quattro. L'unica discordanza riguarda *Carnaval*: l'audio è classificato come *tense*, mentre CLIP associa l'immagine figurativa soprattutto a *happy*. In quel caso il valore 0,227 riportato in tabella è la similarità con *tense*, non il punteggio massimo della classe *happy*. Il movimento e i colori vivaci dell'immagine potrebbero contribuire alla discordanza, ma si tratta di un'interpretazione qualitativa.

6 Discussione dei risultati

La principale evidenza del lavoro è la fattibilità di un collegamento automatico tra analisi del segnale musicale e produzione di contenuti visivi. La selezione a 5 fold identifica Extra Trees a 30 secondi come configurazione operativa più promettente tra quelle esaminate; il confronto con Random Forest invita tuttavia a non attribuire a questa graduatoria un significato assoluto. Inoltre, il riconoscimento di *tense* è più efficace di quello di *sad*. Sul piano generativo, la trasformazione delle feature in descrittori testuali consente di mantenere un legame interpretabile con la musica senza ridurre l'immagine a uno schema grafico prefissato. Il confronto astratto-figurativo evidenzia che modificare lo schema del prompt può cambiare radicalmente il contenuto della scena anche quando audio e seed rimangono invariati. La valutazione CLIP aggiunge un'indicazione quantitativa sulla vicinanza fra immagini e testi emozionali, ma non risolve il problema centrale della validazione percettiva: una concordanza fra due modelli non equivale all'accordo con il giudizio di un ascoltatore.

7 Limiti e sviluppi futuri

Il dataset comprende 900 clip e non rappresenta tutta la varietà dei generi e delle interpretazioni emotive possibili. Il protocollo utilizza un singolo split train/test, senza test statistici di significatività.

Per la rappresentazione visiva, Stable Diffusion v1.5 è usato senza fine-tuning dedicato e può generare artefatti nonostante il negative prompt. Inoltre, CLIP valuta l'affinità semantica immagine-testo, non la percezione musicale umana. Tra gli sviluppi futuri può essere utile anche il confronto con altri modelli di diffusione o GAN, un eventuale fine-tuning su collezioni di arte astratta o figurativa, l'utilizzo di reti neurali applicate agli spettrogrammi e l'analisi di segmenti diversi dello stesso brano. Un'estensione più creativa potrebbe infine produrre sequenze animate sincronizzate con le variazioni musicali.

8 Conclusioni

Il progetto integra elaborazione audio, classificazione supervisionata e generazione text-to-image per trasformare informazioni emozionali musicali in immagini astratte o figurative. La pipeline utilizza il classificatore selezionato tramite cross-validation a 5 fold, Extra Trees a 30 secondi, che sul test set raggiunge accuracy 0,6833 e Macro F1 0,6779. L'emozione predetta viene combinata con descrittori del brano nella costruzione di prompt per Stable Diffusion, permettendo rappresentazioni differenti anche all'interno della stessa categoria emozionale.

Il confronto tra modalità mostra la flessibilità del passaggio dalla musica al linguaggio visivo; la valutazione CLIP, con concordanza tra etichette audio e immagini in 4/4 casi astratti e 3/4 figurativi, offre soltanto una verifica semantica preliminare. Il risultato complessivo va quindi letto soprattutto come dimostrazione di una pipeline creativa e riproducibile, la cui validazione emotiva richiede ancora un campione più ampio e il coinvolgimento di valutatori umani.

Riproducibilità

Il progetto è stato sviluppato in Python su Google Colab, utilizzando principalmente NumPy, pandas, librosa, scikit-learn, Matplotlib, joblib, PyTorch e Diffusers. Il codice del progetto è disponibile nel repository:

https://github.com/silmucci/Artificial-Intelligence-From-Engineering-To-Arts.git

A Prompt utilizzato negli esperimenti

```
# 19) Costruzione del prompt artistico

# 'abstract': immagine astratta
# 'figurative': immagine con soggetti riconoscibili
VISUAL_MODE = 'figurative'

ABSTRACT_EMOTION_STYLES = {
    'happy': (
        'bright yellow, light blue and pastel colors, '
        'rounded shapes, joyful movement, '
        'open composition, warm light'
    ),
    'calm': (
        'soft green, beige and pale blue colors, '
        'smooth waves, minimal composition, '
        'relaxed atmosphere'
    ),
    'tense': (
        'dark red and black colors, '
        'fragmented sharp shapes, '
        'chaotic composition, dramatic shadows, '
        'high contrast'
    ),
    'sad': (
        'deep blue, violet and grey colors, '
        'soft blurred shapes, slow movement, '
        'melancholic atmosphere, low contrast'
    ),
}

# Non vengono imposti luoghi o soggetti specifici.
# Si indica soltanto l'emozione da rappresentare.
FIGURATIVE_EMOTION_STYLES = {
    'happy': (
        'a recognizable figurative scene expressing joy, '
        'optimism, vitality and emotional openness'
    ),
    'calm': (
        'a recognizable figurative scene expressing calm, '
        'serenity, balance and emotional quietness'
    ),
    'tense': (
        'a recognizable figurative scene expressing tension, '
        'instability, urgency and emotional intensity'
    ),
    'sad': (
        'a recognizable figurative scene expressing sadness, '
        'solitude, melancholy and introspection'
    ),
}

NEGATIVE_PROMPTS = {
    'abstract': (
        'text, letters, words, watermark, signature, '
        'realistic faces, people, recognizable objects, '
        'photorealistic scene, logo'
    ),
    'figurative': (
        'text, letters, words, watermark, signature, logo, '
        'bad anatomy, deformed body, extra limbs, '
        'extra fingers, malformed hands, duplicated subjects, '
        'distorted face, blurry, low quality'
    ),
}

if VISUAL_MODE not in {'abstract', 'figurative'}:
    raise ValueError(
        "VISUAL_MODE deve essere 'abstract' oppure 'figurative'."
    )

NEGATIVE_PROMPT = NEGATIVE_PROMPTS[VISUAL_MODE]
```

```
def build_prompt(emotion, features, references):

    if emotion not in ABSTRACT_EMOTION_STYLES:
        raise ValueError(
            f'Emozione non supportata: {emotion}'
        )

    # MODALITA ASTRATTA
    if VISUAL_MODE == 'abstract':

        descriptors = [
            'abstract digital artwork',
            ABSTRACT_EMOTION_STYLES[emotion],
            'visual interpretation of musical emotion',
            'non figurative composition',
        ]

        # Tempo musicale
        if features['tempo'] >= references['tempo_median']:
            descriptors.append(
                'rapid visual rhythm and dynamic composition'
            )
        else:
            descriptors.append(
                'slow visual rhythm and fluid composition'
            )

        # Energia
        if (
            features['energy_mean']
            >= references['energy_median']
        ):
            descriptors.append(
                'vivid colors and energetic brush strokes'
            )
        else:
            descriptors.append(
                'delicate colors and soft transitions'
            )

        # Centroide spettrale
        if (
            features['spectral_centroid_mean']
            >= references['spectral_centroid_median']
        ):
            descriptors.append(
                'luminous highlights and airy textures'
            )
        else:
            descriptors.append(
                'deep tones and dense textures'
            )

        # Modo maggiore o minore
        if int(features['mode_binary']) == 1:
            descriptors.append(
                'harmonious and expansive visual balance'
            )
        else:
            descriptors.append(
                'introspective and suspended visual balance'
            )

    # MODALITA FIGURATIVA
    else:

        descriptors = [
            'figurative cinematic digital artwork',
            FIGURATIVE_EMOTION_STYLES[emotion],
            'recognizable subjects and environment',
            'creative and original visual interpretation',
            'the scene must communicate the musical emotion',
```

```
        'detailed coherent composition',
        'cinematic atmosphere',
    ]

    # Il tempo influenza il movimento visivo.
    if features['tempo'] >= references['tempo_median']:
        descriptors.append(
            'dynamic scene, visible movement, '
            'energetic perspective and visual rhythm'
        )
    else:
        descriptors.append(
            'still scene, gentle movement, '
            'balanced and contemplative composition'
        )

    # L'energia influenza intensita, luce e saturazione.
    if (
        features['energy_mean']
        >= references['energy_median']
    ):
        descriptors.append(
            'strong cinematic lighting, '
            'intense atmosphere and saturated colors'
        )
    else:
        descriptors.append(
            'soft diffused lighting, '
            'delicate atmosphere and muted colors'
        )

    # Il centroide influenza luminosita e densita.
    if (
        features['spectral_centroid_mean']
        >= references['spectral_centroid_median']
    ):
        descriptors.append(
            'bright atmosphere, crisp highlights, '
            'clear details and airy environment'
        )
    else:
        descriptors.append(
            'deep shadows, darker tones, '
            'dense atmosphere and soft details'
        )

    # Il modo influenza il carattere della scena.
    if int(features['mode_binary']) == 1:
        descriptors.append(
            'open, harmonious and hopeful visual balance'
        )
    else:
        descriptors.append(
            'introspective, suspended and emotionally '
            'complex visual balance'
        )

return ', '.join(descriptors)
```

Listing 1: Costruzione del prompt artistico nelle modalita astratta e figurativa.

Riferimenti bibliografici

[1] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," *Proceedings of the 38th International Conference on Machine Learning*, PMLR, vol. 139, pp. 8748–8763, 2021.

[2] J. A. Russell, "A Circumplex Model of Affect," *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980.

[3] R. Panda, R. Malheiro and R. P. Paiva, "Novel Audio Features for Music Emotion Recognition," *IEEE Transactions on Affective Computing*, vol. 11, no. 4, pp. 614–626, 2020.

[4] B. McFee et al., "librosa: Audio and Music Signal Analysis in Python," in *Proceedings of the 14th Python in Science Conference*, pp. 18–25, 2015.

[5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[6] I. Goodfellow et al., "Generative Adversarial Nets," in *Advances in Neural Information Processing Systems*, vol. 27, 2014.

[7] J. Ho, A. Jain and P. Abbeel, "Denoising Diffusion Probabilistic Models," in *Advances in Neural Information Processing Systems*, vol. 33, pp. 6840–6851, 2020.

[8] R. Rombach, A. Blattmann, D. Lorenz, P. Esser and B. Ommer, "High-Resolution Image Synthesis with Latent Diffusion Models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10684–10695, 2022.